Rilevamento automatico di fratture in radiografie pediatriche dell'avambraccio mediante Image Processing e Machine Learning

Daniela Spitaleri Vincenzo Sauzullo Marco Vizzaccaro

Progetto di Image Processing and Analysis – Machine Learning

Codice sorgente GitHub: https://github.com/danielaspitaleri3/Bone_Fracture_Detection

1. Introduzione

1.1 Obiettivo del lavoro

Il progetto realizza una pipeline automatica per il rilevamento di fratture in radiografie pediatriche dell'avambraccio. A differenza di un classificatore che assegna una sola etichetta all'intera immagine, il sistema opera a livello di *detection*: analizza la radiografia per individuare le regioni sospette — ossia bounding box candidate — che vengono poi filtrate da un modello di Machine Learning. In questo modo non viene segnalata soltanto la presenza di una possibile frattura, ma anche la sua posizione.

La pipeline è concepita come supporto alla revisione, non come sostituto della valutazione medica. Nelle radiografie pediatriche le fratture possono presentarsi poco contrastate, sottili o localizzate in zone anatomiche complesse: per questo la prima fase del sistema privilegia la sensibilità, generando anche candidati ridondanti, mentre la seconda fase, basata su Machine Learning, riduce falsi positivi e duplicati.

Nel complesso l'elaborazione si articola in quattro stadi consecutivi: generazione delle ROI candidate tramite Image Processing in C++, estrazione delle feature, filtro supervisionato dei falsi positivi e post-processing con Non-Maximum Suppression. A valle si collocano la valutazione *detection-level* sul test set e l'interfaccia grafica di revisione.

2. Dataset, ground truth e criteri di valutazione

Il dataset impiegato è **GRAZPEDWRI-DX**, una raccolta pubblica di radiografie traumatiche pediatriche dell'avambraccio disponibile su Figshare.[1] Nel progetto ne è stato utilizzato un sottoinsieme operativo di 1203 immagini. Ogni radiografia è corredata da un file di annotazione in formato YOLO, che descrive gli oggetti presenti tramite bounding box normalizzati.

Il dataset originale contiene più classi, ma in questo lavoro si considera unicamente la classe **3**, corrispondente a *fracture*. Tutte le annotazioni di altre classi vengono ignorate in ogni fase — costruzione delle label per il Machine Learning, visualizzazione nella GUI e valutazione finale — così che l'intero sistema sia misurato esclusivamente sulla capacità di individuare le fratture.

2.1 Formato delle annotazioni YOLO

Ogni riga di un file YOLO ha la struttura

$$\text{class_id} \quad x_c \quad y_c \quad w \quad h,$$

in cui i cinque valori indicano:

- `class_id`: classe dell'oggetto annotato; nel progetto si mantiene solo `class_id = 3`, cioè *fracture*;
- `x_c`: coordinata orizzontale del centro del box, normalizzata rispetto alla larghezza dell'immagine;
- `y_c`: coordinata verticale del centro del box, normalizzata rispetto all'altezza dell'immagine;
- `w`: larghezza del box, normalizzata rispetto alla larghezza dell'immagine;
- `h`: altezza del box, normalizzata rispetto all'altezza dell'immagine.

Tutte le coordinate sono quindi comprese tra 0 e 1. L'origine del sistema di riferimento è nell'angolo in alto a sinistra: l'asse x cresce verso destra, l'asse y verso il basso.

2.2 Conversione in pixel e metrica IoU

Per confrontare le annotazioni con le ROI prodotte automaticamente, i valori normalizzati vengono convertiti in coordinate in pixel. Ogni annotazione *fracture* diventa così un bounding box in pixel, direttamente confrontabile con quelli generati dal sistema.

Il confronto tra una ROI candidata e una ground truth si basa sulla metrica *Intersection over Union*:

$$\text{IoU} = \frac{\text{area di intersezione tra i due box}}{\text{area di unione tra i due box}}.$$

Una ROI è quindi considerata sovrapposta in modo sufficiente a una frattura reale quando l'area di intersezione copre almeno il 50% dell'area di unione tra i due box.

Questa regola viene utilizzata in due fasi distinte della pipeline. Nella fase di costruzione del dataset per il machine learning, una ROI viene etichettata come positiva se presenta una sovrapposizione con una ground truth di frattura pari ad almeno 0.50; in caso contrario viene etichettata come negativa. Nella fase di valutazione finale sul test set, invece, lo stesso criterio viene usato per stabilire se una detection può essere considerata una vera positiva. In fase di valutazione finale, ogni ground truth di frattura può essere associata al massimo a una sola detection. Se più ROI candidate si sovrappongono alla stessa frattura reale, viene selezionata come vera positiva la ROI con probabilità ML più alta, mentre le altre vengono considerate duplicati e non vengono conteggiate come ulteriori vere positive.

Tabella 1: Dataset, annotazioni e criteri di valutazione.

Voce	Valore
Dataset originale	GRAZPEDWRI-DX
Dominio	radiografie traumatiche pediatriche dell'avambraccio
Sottoinsieme usato	1203 immagini
Formato annotazioni	YOLO normalizzato
Classe target	YOLO 3 = *fracture*
Classi ignorate	tutte le classi diverse da 3
Coordinate YOLO	centro del box e dimensioni normalizzate tra 0 e 1
Conversione	da coordinate normalizzate a coordinate in pixel
Split	train / validation / test a livello di immagine
Criterio TP	IoU ≥ 0.50

3. Architettura software

Il progetto si articola in due blocchi principali. Il blocco C++, basato su OpenCV e sulle librerie UCAS, genera

[1] https://figshare.com/articles/dataset/GRAZPEDWRI-DX/14825193?file=35026432

le ROI candidate e i CSV di feature. Il blocco Python addestra il filtro ML, valuta il risultato sul test set e fornisce l'interfaccia grafica di revisione.

Tabella 2: Moduli principali coerenti con il codice finale.

File	Ruolo
`main.cpp`	Menu principale del programma C++. Serve ad avviare le diverse modalità operative, in particolare l'estrazione massiva delle ROI candidate e delle feature, che produce i CSV usati successivamente per il training del modello ML.
`functions.cpp`, `functions.h`	Implementano la parte IPA: normalizzazione, enhancement, segmentazione ossea, ricerca delle ROI interne ed esterne, confronto IoU con le ground truth e salvataggio dei CSV e delle ROI candidate.
`fracture_fp_filter.py`	Script di training supervisionato. Confronta i CSV di feature, applica lo split train/validation/test a livello di immagine, usa undersampling solo sul training set, esegue il tuning dei modelli e salva il classificatore finale.
`evaluate_test_postprocess.py`	Script di valutazione finale sul test set. Valuta solo la configurazione **NMS**, genera le curve Precision–Recall e FROC e salva il file JSON con i parametri usati dalla GUI.
`pipeline_gui.py`	Interfaccia grafica di revisione. Non rilancia il codice C++: legge i CSV già prodotti, carica il modello ML salvato, applica la soglia operativa e mostra il risultato finale dopo NMS.

4. Fase IPA: generazione delle ROI candidate

La fase di Image Processing and Analysis ha il compito di proporre automaticamente le zone sospette. In questo stadio il sistema non decide ancora se una ROI sia davvero una frattura: si limita a generare candidati, che saranno poi classificati dal modello supervisionato.

La pipeline IPA lavora con due rami complementari. Il ramo esterno cerca irregolarità del profilo corticale; il ramo interno cerca discontinuità locali di gradiente, contrasto e intensità all'interno della maschera ossea. L'uso combinato dei due rami è necessario per gestire fratture di aspetto diverso: alcune alterano il contorno esterno dell'osso, altre sono più visibili come linea o variazione interna.

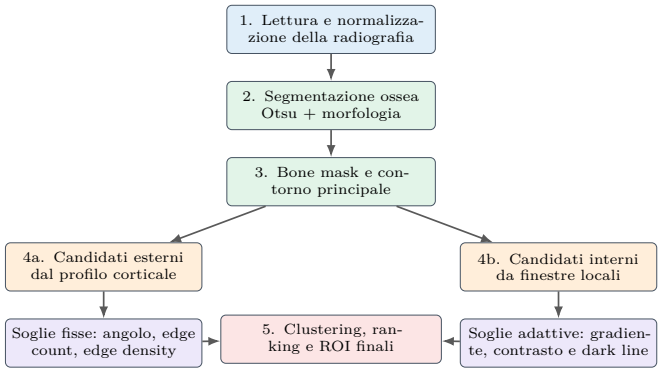


Figura 1: Schema della fase IPA. La generazione delle ROI combina ramo esterno e ramo interno, seguiti da clustering e ranking.

4.1 Normalizzazione, maschera ossea ed enhancement

La prima fase della pipeline ha l'obiettivo di ottenere una rappresentazione uniforme della radiografia e di isolare la regione ossea su cui verranno cercate le ROI candidate. Le immagini acquisite con dinamica superiore agli 8 bit vengono convertite in formato a 8 bit, così da rendere omogenei i valori di intensità e compatibili i successivi algoritmi di elaborazione. Sull'immagine normalizzata viene applicata una prima sogliatura globale di Otsu; successivamente, tramite selezione della componente connessa principale, viene isolata la regione corrispondente al corpo del paziente, eliminando gran parte dello sfondo della lastra.

A partire da questa prima maschera, l'immagine normalizzata viene migliorata tramite equalizzazione adattiva CLAHE, che aumenta il contrasto locale e rende più distinguibili le strutture anatomiche. La soglia di Otsu viene quindi ricalcolata all'interno della maschera del corpo e corretta con un offset, in modo da separare più accuratamente l'area ossea dal resto dell'immagine. La maschera ossea così ottenuta viene infine raffinata mediante operazioni morfologiche di apertura e chiusura, selezione della componente principale e riempimento dei buchi.

La maschera ossea viene poi usata per limitare il calcolo degli edge alla sola regione di interesse. In particolare, il rilevatore Canny viene applicato su una versione dell'immagine normalizzata circoscritta alla maschera ossea e leggermente filtrata con Gaussian blur. In questo modo gli edge dovuti a sfondo, testo laterale, cute o bordi della radiografia non contribuiscono alla generazione dei candidati. Gli edge ottenuti in questa fase sono utilizzati soprattutto dal ramo esterno, che ricerca irregolarità lungo il profilo corticale dell'osso.

In parallelo viene generata un'immagine enhanced, ottenuta applicando CLAHE e sharpening all'immagine normalizzata, mantenendo l'elaborazione all'interno della regione ossea. Questa immagine non viene utilizzata per costruire la maschera ossea né per calcolare gli edge Canny del ramo esterno. Viene invece impiegata per la visualizzazione, per l'analisi locale del ramo interno e per i crop usati nell'estrazione delle feature. In particolare, il ramo interno lavora sull'immagine enhanced per evidenziare variazioni locali di intensità, contrasto e gradiente che possono indicare discontinuità interne compatibili con una frattura.

4.2 ROI esterne

Le ROI esterne vengono cercate lungo il contorno principale dell'osso. Il codice campiona il profilo, confronta la direzione del bordo prima e dopo ogni punto e misura il cambio angolare. Un punto diventa candidato solo se soddisfa contemporaneamente tre condizioni: cambio di direzione almeno pari a 20°, numero minimo di edge nella finestra locale e densità minima di edge. Vengono inoltre esclusi i punti vicini ai bordi del bounding box osseo e le zone verticali troppo alte o troppo basse dell'immagine.

Ogni candidato esterno riceve uno score che combina cambio angolare, numero di edge e densità di edge. I candidati vengono poi ordinati per score e filtrati imponendo una distanza minima, in modo da ridurre i box quasi sovrapposti sullo stesso tratto corticale.

4.3 ROI interne

Le ROI interne vengono cercate dentro una maschera ossea erosa, così da non far dominare il bordo corticale. Il codice calcola una mappa di gradiente interno e scansiona la regione con finestre locali. Per ogni finestra misura media e deviazione standard dei grigi, media e deviazione standard del gradiente, picco di gradiente e differenza tra grigio medio e valore minimo della finestra.

Le soglie interne non sono soltanto fisse: il codice ne calcola anche di adattive a partire dalla distribuzione delle finestre analizzate nella singola immagine. Una finestra viene accettata se supera una combinazione di test stringenti su gradiente, variabilità dei grigi e presenza di una possibile linea scura. I candidati interni vengono infine

raggruppati con un criterio di clustering che tiene conto di score, centralità e supporto locale.

4.4 Unione delle ROI e assegnazione delle label IoU

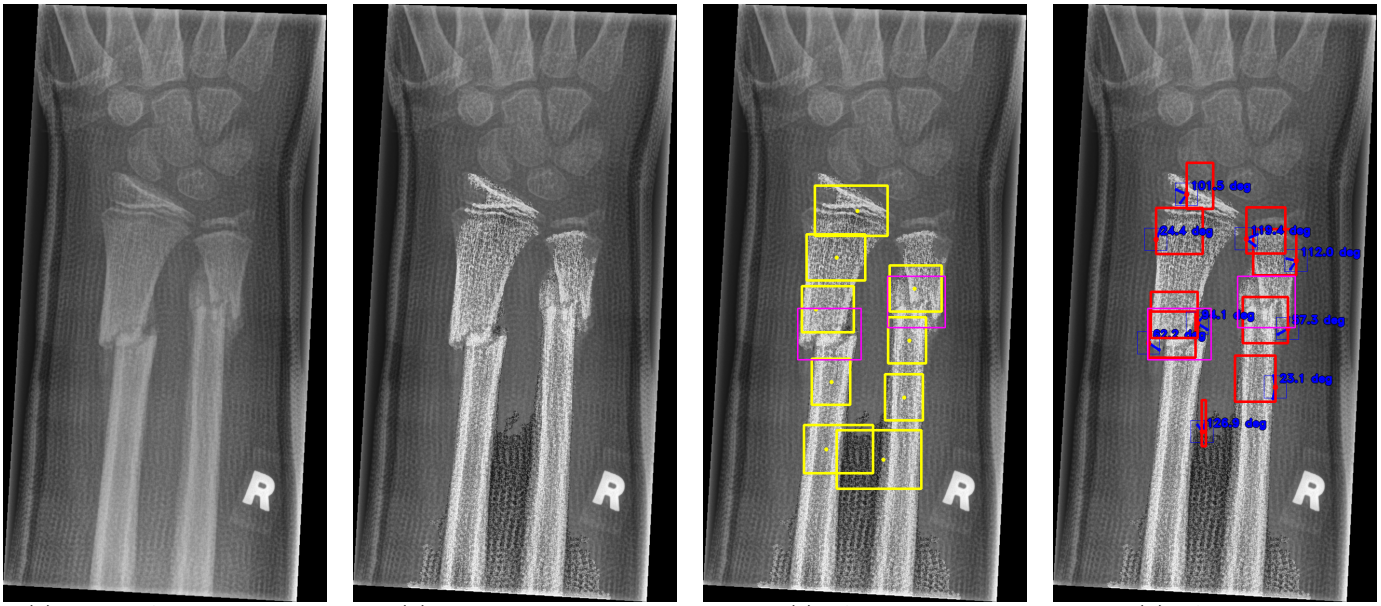
I candidati interni ed esterni vengono uniti e ordinati per score. L'obiettivo del blocco C++ è produrre ROI candidate sensibili e salvarle nei CSV. Per ogni ROI vengono registrati immagine, identificativo, metodo di origine, coordinate, score, migliore IoU con la ground truth e label binaria. La label vale 1 se IoU ≥ 0.50, altrimenti 0.

4.5 Esempi visivi della pipeline IPA

Le figure seguenti mostrano due esempi qualitativi utili per interpretare il comportamento dei due rami della pipeline IPA. Le etichette `INTERNAL` ed `EXTERNAL` identificano il ramo algoritmico che ha generato la ROI candidata. Il ramo `EXTERNAL` analizza principalmente il profilo corticale dell'osso e cerca variazioni brusche del contorno, mentre il ramo `INTERNAL` lavora all'interno della maschera ossea e ricerca variazioni locali di intensità, contrasto e gradiente.

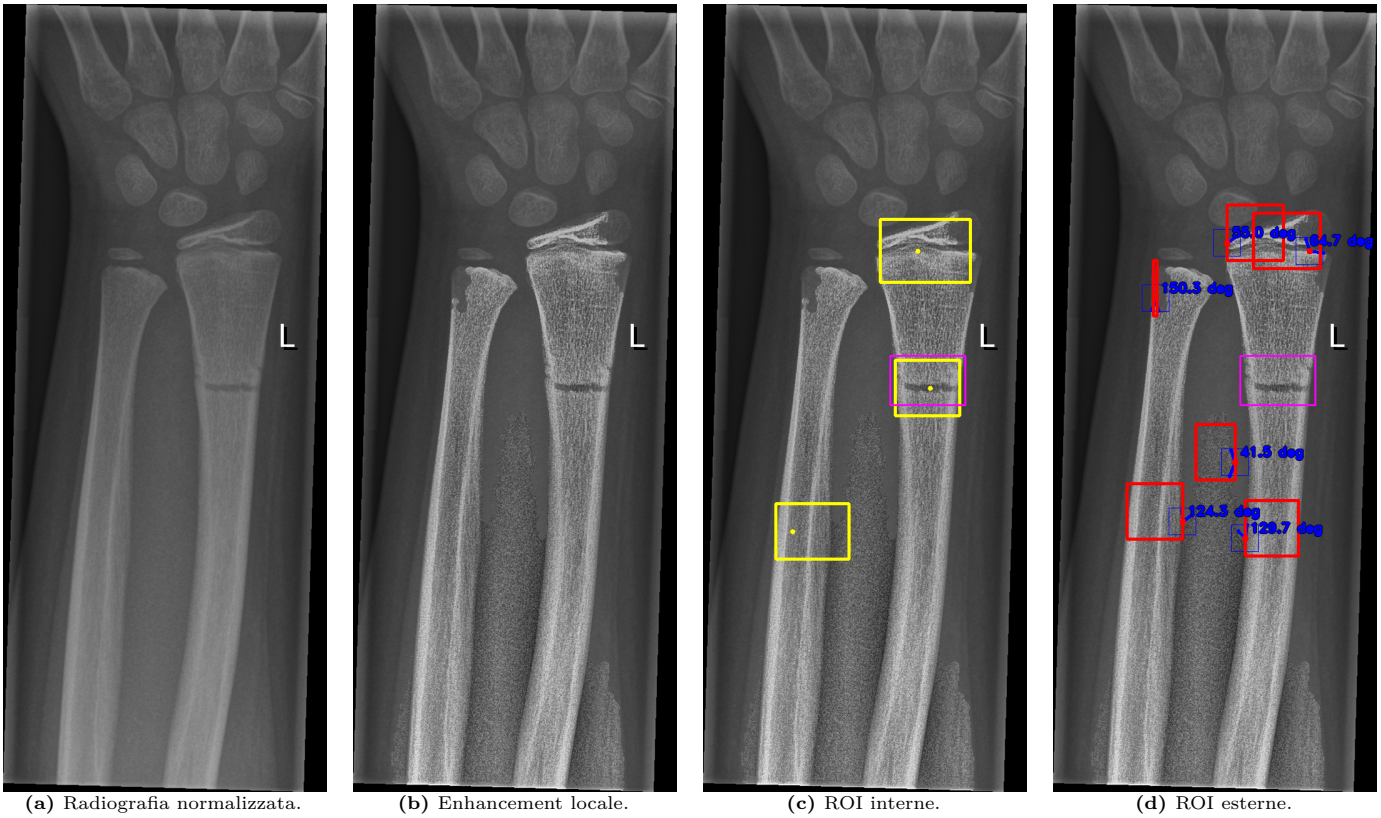
Il primo esempio rappresenta un caso in cui la zona sospetta modifica in modo evidente il profilo esterno dell'osso. La discontinuità non si manifesta principalmente come una variazione interna di texture, ma come un'alterazione del bordo corticale: il contorno osseo presenta una deviazione locale rispetto all'andamento regolare atteso. Per questo motivo il ramo esterno risulta più efficace, poiché è progettato per campionare il profilo dell'osso e individuare punti in cui la direzione del bordo cambia bruscamente. In questo caso, quindi, la ROI più significativa viene generata dal ramo `EXTERNAL`, mentre il ramo `INTERNAL` risulta meno informativo perché la frattura non è descritta soprattutto da una variazione locale all'interno della regione ossea.

Il secondo esempio mostra invece una situazione diversa: la zona sospetta non produce una marcata irregolarità del contorno corticale esterno, ma è descritta soprattutto da variazioni locali all'interno della regione ossea. In questo caso l'informazione più utile non è il cambiamento della forma del bordo, bensì la presenza di discontinuità interne visibili come variazioni di intensità e di gradiente nell'immagine enhanced. Il ramo `INTERNAL` è quindi più adatto, perché analizza finestre locali interne alla maschera ossea e valuta statistiche come gradiente medio, picco di gradiente, variabilità dei grigi e presenza di zone più scure. La ROI più significativa viene quindi prodotta dal ramo interno, mentre il ramo esterno risulta meno efficace perché il profilo corticale non presenta una deformazione abbastanza evidente da generare un candidato affidabile.



(a) Radiografia normalizzata. **(b)** Enhancement locale. **(c)** ROI interne. **(d)** ROI esterne.

Figura 2: Caso 1: esempio in cui la risposta prevalente è prodotta dal ramo esterno.



(a) Radiografia normalizzata. **(b)** Enhancement locale. **(c)** ROI interne. **(d)** ROI esterne.

Figura 3: Caso 2: esempio in cui la risposta prevalente è prodotta dal ramo interno.

5. Estrazione delle feature

Dopo la generazione delle ROI candidate, il blocco C++ estrae da ciascun crop un insieme di feature numeriche descrittive. Il crop utilizzato per il calcolo delle feature viene leggermente espanso rispetto al bounding box originale, aggiungendo un piccolo contesto anatomico attorno alla regione sospetta. Questa scelta consente di includere anche le strutture vicine alla ROI, che possono essere utili per descrivere meglio la discontinuità locale. Il box usato per la detection e per il calcolo dell'IoU, invece, rimane invariato, così da non alterare il confronto con la ground truth. Il margine aggiunto al crop è pari all'8% della dimensione della ROI, con un limite minimo di 6 pixel e massimo di 18 pixel.

Le feature estratte appartengono principalmente a tre famiglie: GLCM, LBP e HOG. Le feature GLCM descrivono la texture attraverso le relazioni di co-occorrenza tra livelli di grigio; le feature LBP rappresentano i micro-pattern locali di intensità; le feature HOG descrivono invece la distribuzione dei gradienti e quindi la presenza di strutture orientate o discontinuità lineari. In questo modo, ogni ROI viene rappresentata sia dal punto di vista della texture sia dal punto di vista della forma locale dei gradienti.

Il CSV completo contiene i metadati della ROI e tutte le famiglie di feature estratte, mentre CSV separati vengono prodotti per valutare singolarmente il contributo di GLCM, LBP, HOG e della loro combinazione. Questa organizzazione permette al blocco Python di confrontare diversi insiemi di descrittori e di stabilire sperimentalmente quali risultino più efficaci per distinguere le ROI realmente

associate a frattura dai falsi positivi generati dall'Image Processing.

Poiché il numero complessivo di feature può essere elevato, soprattutto quando si combinano GLCM, LBP e HOG, nella fase di Machine Learning viene applicata una riduzione della dimensionalità tramite PCA per i modelli che ne beneficiano, come SVM e KNN. La PCA non seleziona direttamente una singola feature originale, ma costruisce un numero ridotto di componenti principali che riassumono l'informazione più rilevante contenuta nei descrittori. Nel progetto il valore utilizzato per la PCA è pari a 30 componenti.

La scelta finale del modello non viene quindi fatta manualmente sulla base di una singola famiglia di feature, ma tramite confronto sperimentale su validation set. Tra le configurazioni valutate, la combinazione GLCM+LBP+HOG associata a un classificatore SVM-RBF è risultata la più efficace e viene quindi utilizzata come modello finale. Questa scelta è coerente con la natura del problema: le fratture possono manifestarsi sia come variazioni di texture, sia come micro-pattern locali, sia come discontinuità di gradiente, per cui la combinazione delle tre famiglie di feature fornisce una descrizione più completa della ROI.

Tabella 3: Feature prodotte dal modulo C++.

Famiglia	Descrizione
GLCM	7 misure di texture — contrasto, dissimilarità, omogeneità, ASM, energia, entropia e correlazione — calcolate su 16 livelli e più direzioni.
LBP	Istogramma normalizzato a 256 componenti, utile per i micro-pattern locali e le variazioni fini dell'intensità.
HOG	Descrittore dei gradienti con celle 8×8, blocchi 16×16 e 9 orientamenti; il codice usa una finestra HOG coerente e multipla di 8.
Metadati	Immagine, id ROI, metodo `INTERNAL/EXTERNAL`, coordinate, score, file crop, migliore IoU e label.

6. Machine Learning

La fase ML ha il compito di filtrare i falsi positivi prodotti dall'IPA. Lo script `fracture_fp_filter.py` confronta più CSV di feature, più classificatori e più configurazioni di preprocessing. Il modello finale resta supervisionato: viene scelto sulla validation e valutato sul test set.

6.1 Split, anti-leakage e undersampling

Lo split del dataset viene eseguito a livello di immagine e non a livello di singola ROI. Questa scelta è fondamentale per evitare il data leakage: se ROI diverse provenienti dalla stessa radiografia fossero distribuite contemporaneamente tra training, validation e test, il modello potrebbe apprendere caratteristiche specifiche dell'immagine invece di generalizzare su radiografie nuove. Per questo motivo tutte le ROI generate dalla stessa immagine vengono assegnate allo stesso sottoinsieme.

Dopo lo split, l'undersampling viene applicato esclusivamente al training set. Questa operazione riduce il numero di ROI negative, cioè i falsi candidati prodotti dalla fase IPA, mantenendo invece le ROI positive associate a fratture. L'obiettivo è attenuare lo sbilanciamento tra classi: poiché il sistema di Image Processing genera molte più ROI non fratturate rispetto a quelle realmente sovrapposte a una ground truth, un training completamente sbilanciato potrebbe portare il classificatore a privilegiare eccessivamente la classe negativa.

L'undersampling non viene applicato a validation e test. Questi due insiemi vengono mantenuti nella loro distribuzione reale, così da fornire una stima più attendibile delle prestazioni del modello su dati non modificati. In questo modo il training viene reso più bilanciato per facilitare l'apprendimento, mentre validation e test restano rappresentativi dello scenario operativo, in cui il numero di falsi candidati può essere elevato.

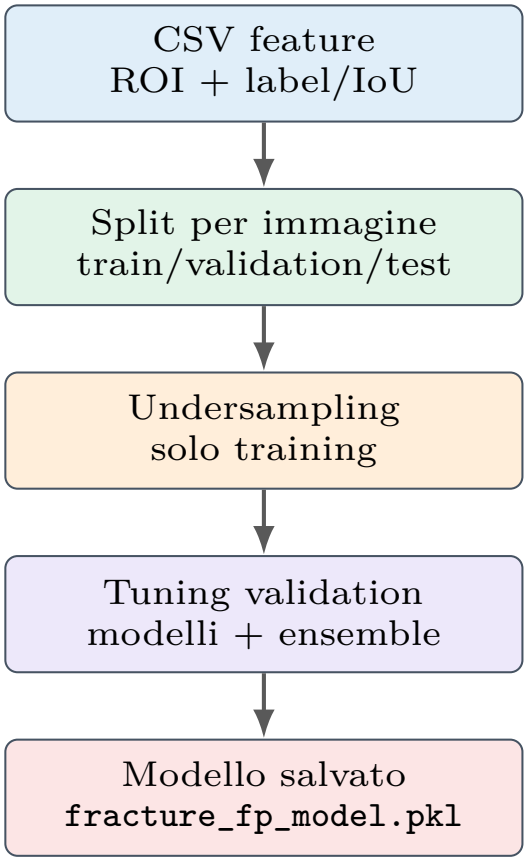


Figura 4: Procedura ML. Lo split è a livello di immagine; l'undersampling viene applicato solo al training.

6.2 Confronto sperimentale

La fase sperimentale ha l'obiettivo di individuare la configurazione più efficace per classificare le ROI candidate prodotte dalla fase IPA. Ogni ROI viene descritta tramite un vettore di feature e viene associata a una label binaria: positiva se la ROI si sovrappone a una ground truth di frattura con IoU sufficiente, negativa altrimenti. Il compito del modello supervisionato è quindi distinguere le ROI realmente compatibili con una frattura dai falsi positivi generati dall'Image Processing.

Lo script di training confronta cinque sorgenti CSV prodotte dal blocco C++: GLCM, GLCM+LBP+HOG, HOG e LBP. Ogni CSV viene trattato come una diversa rappresentazione del problema. Questo permette di verificare se le singole famiglie di feature siano sufficienti oppure se la combinazione dei descrittori fornisca una rappresentazione più robusta della ROI.

Il confronto non riguarda soltanto le feature, ma anche le metodologie di classificazione. Sono stati considerati modelli lineari e non lineari. La SVM lineare viene usata come riferimento semplice, adatto a separazioni approssimativamente lineari nello spazio delle feature. La SVM-RBF utilizza invece un kernel radiale, quindi può modellare separazioni più complesse tra ROI positive e negative. KNN classifica una ROI in base alla vicinanza rispetto agli esempi già presenti nel training set, mentre Random Forest combina più alberi decisionali per ottenere

una classificazione più stabile e meno dipendente da una singola regola di separazione.

Nella modalità estesa vengono valutate anche due strategie ensemble supervisionate. Il Soft Voting combina le probabilità prodotte da più classificatori e assegna la classe finale in base alla media degli score. Lo Stacking, invece, utilizza le predizioni dei modelli base come nuovo input per un classificatore finale, che apprende come combinarle. Queste tecniche non sono quindi semplici modelli aggiuntivi, ma metodi per fondere le decisioni di più classificatori.

Il tuning degli iper-parametri viene effettuato sulla validation set. In questo modo la scelta del modello, della soglia e della configurazione di preprocessing non dipende direttamente dal test set. Il test set viene usato solo dopo la selezione della configurazione, per verificare la capacità di generalizzazione su immagini non utilizzate durante il training e il tuning.

Per i modelli più sensibili alla scala e alla dimensionalità delle feature, come SVM e KNN, viene applicata una normalizzazione dei descrittori. Nella configurazione finale riportata in tabella la normalizzazione selezionata è quella standard. Inoltre, per SVM e KNN può essere applicata la PCA. Nel progetto sono state usate 30 componenti principali: questo significa che il vettore originale di feature viene trasformato in una rappresentazione più compatta formata da 30 nuove componenti. La PCA non sceglie manualmente le 30 feature migliori, ma costruisce combinazioni delle feature originali che riassumono gran parte dell'informazione utile, riducendo ridondanza e dimensionalità.

La soglia di decisione del classificatore viene studiata sulla validation set variando il threshold applicato allo score ML. Per ogni soglia vengono calcolate precision, recall e una metrica F_β. Nel profilo automatico del codice viene usato $\beta = 2$, quindi la metrica F_2, che assegna un peso maggiore al recall rispetto alla precision. Questa scelta è coerente con il problema affrontato: nella rilevazione assistita di fratture è preferibile ridurre i falsi negativi, anche accettando un numero maggiore di falsi positivi da sottoporre a revisione.

Dai risultati sperimentali la configurazione selezionata è GLCM+LBP+HOG con classificatore SVM-RBF e normalizzazione standard. Questa combinazione risulta efficace perché integra informazioni complementari: GLCM descrive la distribuzione e la co-occorrenza dei livelli di grigio, LBP cattura i micro-pattern locali di intensità e HOG rappresenta la struttura dei gradienti e delle discontinuità orientate.

Nella GUI e nella valutazione finale NMS viene invece usata una soglia operativa fissa e inclusiva pari a ML ≥ 0.50. Questa scelta rende la pipeline finale più semplice e ripetibile: tutte le ROI con score ML almeno pari a 0.50 vengono considerate candidate e vengono poi sottoposte a Non-Maximum Suppression, che elimina i duplicati mantenendo il box con score più alto nelle zone sovrapposte.

6.3 Effetto visivo del filtro ML e della NMS

Dal punto di vista visivo, la differenza tra la fase di candidatura e il risultato finale è evidente. Nella vista **IMAGE PROCESSING** vengono mostrate tutte le ROI candidate generate dal modulo IPA: il sistema privilegia la sensibilità e quindi propone numerosi box, anche ridondanti o lontani dalla frattura reale. In questa fase possono comparire più ROI sovrapposte nella stessa zona anatomica, insieme a candidati distribuiti lungo il radio e nelle regioni vicine al polso.

Dopo il passaggio attraverso il filtro supervisionato, vengono mantenute soltanto le ROI con score ML almeno pari a 0.50. Successivamente la NMS elimina i duplicati tra box sovrapposti, conservando quello con score ML più alto. Il risultato finale è quindi molto più selettivo: nell'esempio mostrato, molte ROI candidate iniziali vengono scartate e rimane una sola detection principale nella zona sospetta. Questa detection viene confrontata con la ground truth YOLO di classe 3 e, se raggiunge IoU ≥ 0.50, viene classificata come vero positivo.

Questo comportamento conferma il ruolo del modello ML: non genera nuove regioni, ma filtra quelle già prodotte dall'image processing. Se una frattura non viene proposta tra le ROI iniziali, il classificatore non può recuperarla; se invece la ROI candidata è presente, il filtro ML e la NMS possono ridurre la ridondanza e mantenere soltanto il box più affidabile.

Caso particolare: ROI duplicate sulla ground truth. Un caso particolare si verifica quando, dopo il filtro ML e la NMS, rimangono più ROI sovrapposte alla stessa ground truth. In questa situazione una sola detection deve essere considerata vero positivo: viene scelta quella con score ML maggiore e con IoU ≥ 0.50 rispetto alla ground truth. Tuttavia, una seconda ROI ancora localizzata sulla stessa frattura non rappresenta un vero falso positivo clinico, perché cade comunque sulla regione annotata come frattura.

Per evitare di penalizzare artificialmente la precisione, viene quindi usata la categoria `IGNORE`: se una ground truth è già stata coperta da un TP, eventuali altre ROI che intersecano quella stessa ground truth con IoU > 0.30 non vengono conteggiate come FP. Queste ROI sono interpretate come duplicati residui o localizzazioni alternative della stessa frattura già rilevata.

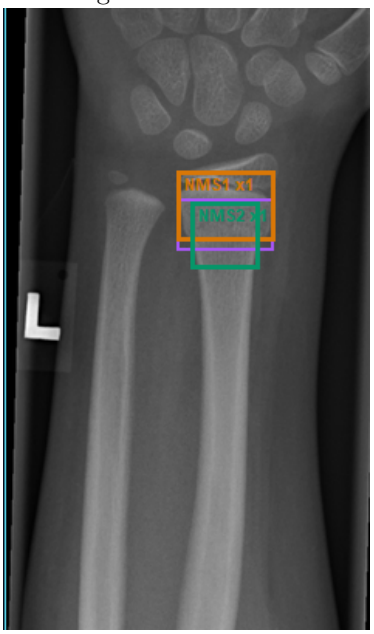
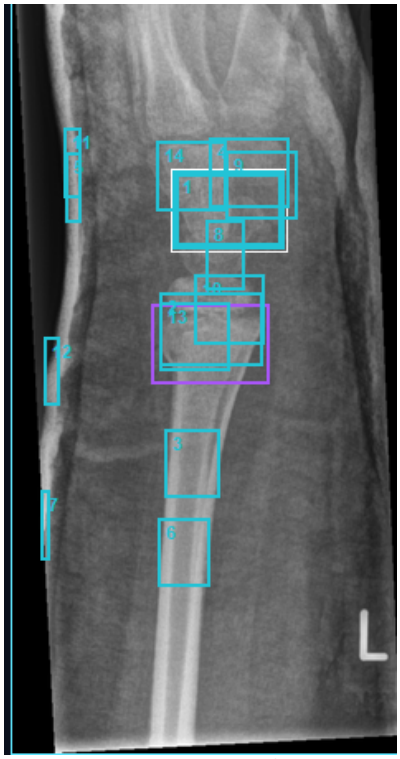
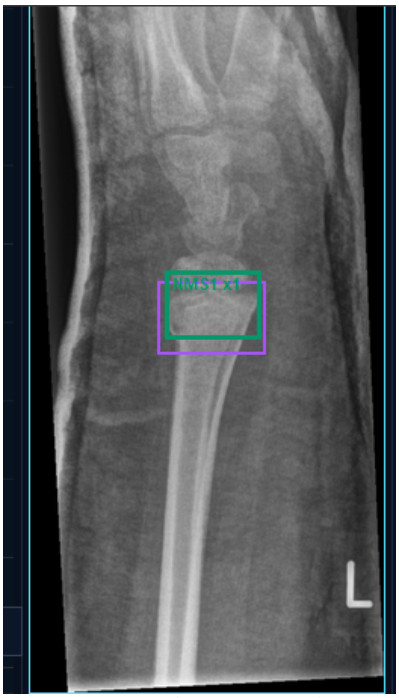


Figura 6: Esempio di categoria `IGNORE`. Una detection viene assegnata come TP sulla ground truth; una seconda ROI ancora sovrapposta alla stessa frattura non viene conteggiata come falso positivo se supera la soglia di intersezione IoU > 0.30.

"'latex



(a) Vista Image Processing: numerose ROI candidate generate dal modulo IPA.



(b) Vista Risultato ML: dopo filtro ML e NMS rimane la detection finale.

Figura 5: Effetto del filtro supervisionato e della NMS. La fase IPA propone molte ROI candidate; il filtro ML mantiene solo quelle con score sufficiente e la NMS sopprime i duplicati, producendo un risultato finale più leggibile.

Tabella 4: Confronto delle principali configurazioni supervisionate. La colonna *Sel* indica il modello salvato.

Rk	CSV feature	Metodo	Norm	Val F1	Val P	Val R	Val AP	Test P	Test R	Test F1	Test AP	Thr	Sel
1	GLCM+LBP+HOG	SVM-RBF	standard	0.6349	0.5448	0.7607	0.5886	0.5468	0.7603	0.6361	0.6776	0.5377	BEST
2	HOG	Ensemble Stacking*	standard	0.6163	0.5196	0.7571	0.5633	0.5190	0.7945	0.6279	0.6776	0.5092	
3	HOG	SVM-RBF	standard	0.6152	0.5197	0.7536	0.5983	0.5121	0.7945	0.6228	0.6612	0.5000	
4	GLCM+LBP+HOG	Ensemble Soft Voting*	standard	0.6063	0.5072	0.7536	0.5513	0.5201	0.7979	0.6297	0.6574	0.4869	
5	HOG	Ensemble Soft Voting*	standard	0.5890	0.4778	0.7679	0.5423	0.4768	0.8082	0.5997	0.6606	0.4541	
6	GLCM+LBP+HOG	KNN	standard	0.5691	0.4585	0.7500	0.5022	0.4617	0.8048	0.5868	0.5371	0.4406	
7	GLCM+LBP+HOG	Random Forest	standard	0.5440	0.4268	0.7500	0.4889	0.4425	0.7911	0.5676	0.6088	0.4450	
8	HOG	KNN	standard	0.5363	0.4090	0.7786	0.4697	0.4144	0.8288	0.5525	0.5383	0.4455	
9	HOG	Random Forest	standard	0.5263	0.4004	0.7679	0.4723	0.3963	0.7979	0.5295	0.5810	0.4350	
10	LBP	Ensemble Stacking*	standard	0.4889	0.3542	0.7893	0.4457	0.3748	0.7945	0.5093	0.5124	0.4101	
11	LBP	SVM-RBF	standard	0.4888	0.3555	0.7821	0.4400	0.3639	0.7603	0.4922	0.5050	0.4588	
12	LBP	Ensemble Soft Voting*	standard	0.4778	0.3506	0.7500	0.4374	0.3744	0.7705	0.5039	0.4910	0.4639	
13	GLCM+LBP+HOG	SVM lineare	standard	0.4778	0.3506	0.7500	0.4757	0.3756	0.7808	0.5072	0.5650	0.4131	
14	HOG	SVM lineare	standard	0.4778	0.3506	0.7500	0.4747	0.3709	0.7774	0.5022	0.5542	0.4104	
15	LBP	Random Forest	standard	0.4590	0.3236	0.7893	0.4048	0.3478	0.8253	0.4893	0.4714	0.4250	
16	LBP	KNN	standard	0.4563	0.3252	0.7643	0.3757	0.3231	0.7568	0.4529	0.4141	0.4725	
17	LBP	SVM lineare	standard	0.3445	0.2190	0.8071	0.2809	0.2270	0.7877	0.3525	0.3272	0.3225	
18	GLCM	SVM-RBF	standard	0.3141	0.1987	0.7500	0.2442	0.1920	0.7568	0.3063	0.2825	0.2944	
19	GLCM	Ensemble Soft Voting*	standard	0.3045	0.1899	0.7679	0.2245	0.1853	0.7705	0.2988	0.2351	0.3248	
20	GLCM	Ensemble Stacking*	standard	0.3043	0.1906	0.7536	0.2406	0.1939	0.7877	0.3112	0.2659	0.2934	
21	GLCM	Random Forest	standard	0.2875	0.1741	0.8250	0.2097	0.1754	0.8151	0.2887	0.2091	0.2850	
22	GLCM	KNN	standard	0.2857	0.1753	0.7714	0.1948	0.1668	0.7603	0.2736	0.1876	0.2461	
23	GLCM	SVM lineare	standard	0.2663	0.1604	0.7821	0.1759	0.1634	0.7705	0.2696	0.2170	0.3330	

*Le configurazioni ensemble combinano i modelli base ottimizzati su validation: SVM-RBF, SVM lineare, KNN e Random Forest. Nel Soft Voting vengono combinate le probabilità dei modelli base; nello Stacking le loro predizioni probabilistiche vengono usate come input per un classificatore finale di regressione logistica.

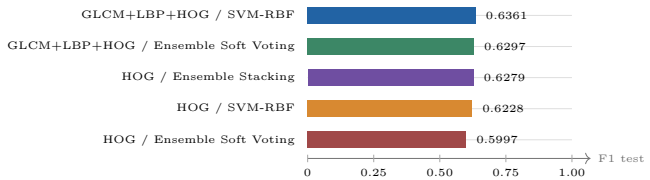


Figura 7: Configurazioni migliori osservate sul test set in termini di F1. Il modello scelto resta GLCM+LBP+HOG con SVM-RBF.

Nel complesso, le feature combinate GLCM+LBP+HOG risultano le più robuste perché descrivono la ROI da punti di vista diversi. HOG da solo resta competitivo, segno che le discontinuità di gradiente sono molto informative per questo problema. Tuttavia, la sola informazione di gradiente non sempre descrive completamente la regione sospetta. L'aggiunta di GLCM e LBP permette di includere anche informazioni di texture e micro-variazioni locali di intensità. Per questo motivo la configurazione GLCM+LBP+HOG con SVM-RBF rappresenta il miglior compromesso sperimentale tra capacità descrittiva, recall e precision.

6.4 Metriche del modello selezionato

Il modello finale salvato è GLCM+LBP+HOG con **SVM-RBF**, normalizzazione standard e soglia selezionata sulla validation pari a 0.5377. Le metriche mostrano valori molto simili tra validation e test, soprattutto per precision, recall e F1. Questo indica che la configurazione scelta non dipende soltanto da una fluttuazione della validation set, ma mantiene prestazioni comparabili anche su dati non utilizzati durante il tuning.

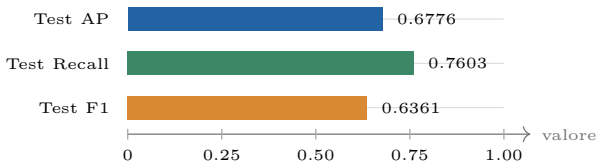


Figura 8: Metriche principali della configurazione selezionata.

Tabella 5: Metriche della configurazione finale GLCM+LBP+HOG + SVM-RBF.

Metrica	Validation	Test
Precision	0.5448	0.5468
Recall / Sensitivity	0.7607	0.7603
F1	0.6349	0.6361
PR AP	0.5886	0.6776
Soglia ML selezionata	0.5377	0.5377

7. Post-processing con Non-Maximum Suppression

Nella fase di post-processing viene applicata la Non-Maximum Suppression (NMS), con l'obiettivo di ridurre la presenza di ROI multiple riferite alla stessa zona sospetta. La fase di image processing e il filtro supervisionato possono infatti produrre più bounding box sovrapposti sulla stessa regione anatomica; senza un ulteriore filtraggio, la visualizzazione finale risulterebbe ridondante e la valutazione detection-level penalizzata da falsi positivi duplicati.

La configurazione operativa considera soltanto le ROI con score ML almeno pari a 0.50. Le ROI rimanenti vengono ordinate in ordine decrescente rispetto allo score del classificatore, così da assegnare priorità ai box considerati più affidabili dal modello. La NMS confronta quindi le ROI candidate tra loro: quando due bounding box presentano una sovrapposizione pari o superiore alla soglia NMS, viene mantenuto il box con score ML maggiore e quello con score inferiore viene soppresso.

La soglia NMS scelta tramite validation è pari a 0.40. Questa soglia non va confusa con il criterio usato per stabilire se una detection è corretta rispetto alla ground truth: per la valutazione dei veri positivi resta fissata la regola IoU ≥ 0.50. In questo modo il post-processing controlla la ridondanza tra detection, mentre la valutazione finale misura la correttezza geometrica rispetto alle annotazioni YOLO della classe frattura.

Il risultato finale è quindi più ordinato e meno ridondante: una stessa regione anatomica non viene rappresentata da molti box quasi identici, ma da una singola detection, corrispondente alla ROI con score ML più alto tra quelle sovrapposte. La stessa configurazione viene usata nella GUI e nella valutazione finale, garantendo coerenza tra visualizzazione, metriche locali e metriche globali.

7.1 Regole di valutazione

La valutazione sul test set carica le immagini dal manifest generato durante l'addestramento, recupera le label YOLO della classe 3 e calcola le metriche sulle detection finali prodotte dopo filtro ML e NMS. La classe 3 viene interpretata come classe frattura; tutte le altre classi non partecipano al conteggio dei veri positivi.

Alla soglia operativa fissa vale la regola ML ≥ 0.50. Una detection è considerata vera positiva se la sua migliore sovrapposizione con una ground truth di frattura soddisfa IoU ≥ 0.50. Se più detection coprono la stessa ground truth, il vero positivo viene assegnato alla detection con score ML maggiore, in modo che ogni frattura annotata possa contribuire al massimo con un solo TP.

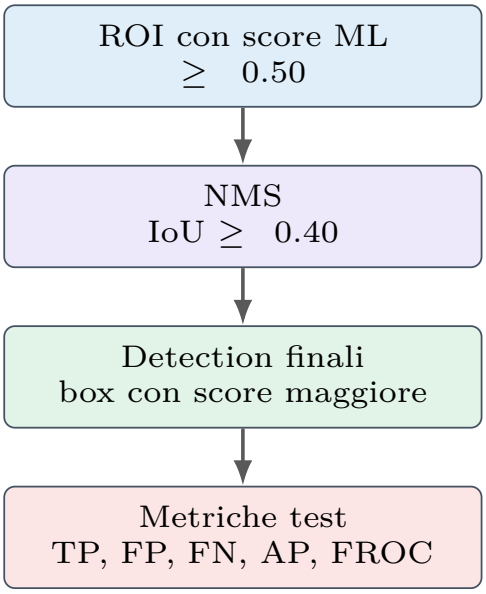


Figura 9: Post-processing finale. La pipeline utilizza una configurazione NMS: le ROI candidate vengono filtrate con soglia ML ≥ 0.50 e poi ridotte mediante NMS.

Per evitare di penalizzare il sistema con falsi positivi duplicati sulla stessa frattura, viene introdotta anche una categoria `IGNORE`. Dopo aver assegnato il TP a una ground truth, eventuali altre ROI che intersecano la stessa ground truth per più del 30%, cioè con IoU > 0.30, non vengono conteggiate come FP. Queste ROI sono considerate duplicati o localizzazioni alternative della stessa frattura già rilevata. In questo modo una seconda ROI posta sulla ground truth, ma non selezionata come TP perché esiste già una detection migliore, non peggiora artificialmente la precisione del sistema.

Le detection finali che non sono TP e che non rientrano nella condizione di `IGNORE` vengono invece conteggiate come falsi positivi. Questa regola distingue quindi tre casi: TP per la migliore detection sulla frattura, `IGNORE` per i duplicati ancora sovrapposti alla ground truth già rilevata, e FP per le detection realmente non corrispondenti ad alcuna frattura annotata.

La valutazione salva il CSV di dettaglio, i punti delle curve, il file `best_postprocess_params.json` usato dalla GUI e i grafici finali. L'Average Precision viene calcolata dalla curva Precision–Recall ottenuta ordinando le detection per confidence score; la FROC riporta invece la sensibilità in funzione del numero di falsi positivi per immagine.

Tabella 6: Parametri principali della configurazione NMS.

Parametro	Valore / significato
Classe GT	YOLO 3 = frattura
Soglia ML operativa	ROI mantenuta se ML ≥ 0.50
Soglie NMS confrontate su validation	0.30, 0.40, 0.50
Soglia NMS selezionata	0.40, scelta in base al miglior F1 su validation
Criterio TP	detection corretta se IoU con GT ≥ 0.50
Categoria `IGNORE`	ROI non TP che interseca una GT già coperta da un TP con IoU > 0.30
Detection FP	detection non TP e non `IGNORE`, quindi non corrispondente a una frattura annotata

7.2 Scelta della soglia NMS su validation

La soglia NMS è stata scelta confrontando tre valori candidati sul set di validation: 0.30, 0.40 e 0.50. Il confronto usa le curve FROC e le metriche al punto operativo ML ≥ 0.50.

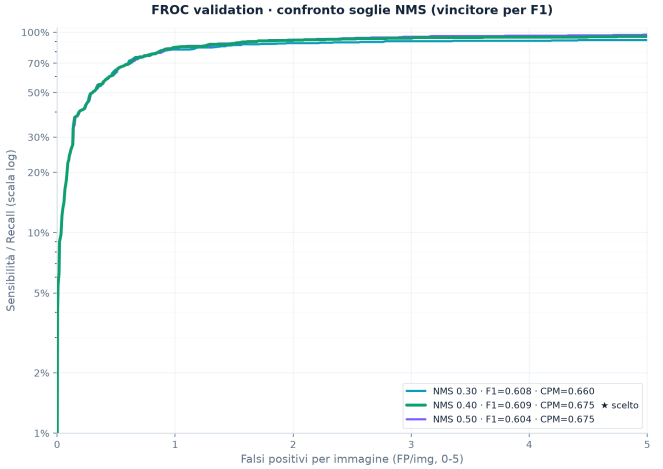


Figura 10: Confronto FROC sul validation set per tre soglie NMS. La soglia 0.40 viene selezionata perché raggiunge il miglior F1 al punto operativo ML ≥ 0.50, mantenendo un CPM pari a 0.675.

Oltre all'F1, viene riportato anche il CPM, calcolato come media delle sensibilità interpolate ai valori di falsi positivi per immagine $\{0.125, 0.25, 0.5, 1, 2, 4\}$.

Tabella 7: Confronto delle soglie NMS sul validation set.

Soglia NMS	F1 validation	CPM validation
0.30	0.608	0.660
0.40	0.609	0.675
0.50	0.604	0.675

Il valore 0.40 ottiene il miglior F1 e mantiene un CPM pari a quello della soglia 0.50. La scelta è quindi coerente con l'obiettivo del sistema: mantenere elevata la sensibilità, ma ridurre la ridondanza delle ROI sovrapposte e limitare i falsi positivi duplicati.

7.3 Curve finali sul test set

La curva Precision–Recall illustra il compromesso tra precisione e sensibilità al variare della soglia ML lungo la curva. Per soglie alte si mantengono poche ROI molto affidabili: la precisione è elevata, ma il recall è basso. Abbassando la soglia si recuperano più fratture, a costo di un aumento dei falsi positivi. L'Average Precision pari a AP = 0.6736 indica che lo score ML ordina in modo complessivamente buono le detection, pur lasciando un margine di errore dovuto alla difficoltà di separare tutte le fratture reali dai falsi allarmi generati dalla fase di candidatura.

La FROC è particolarmente adatta a un problema di detection medica, perché mette in relazione la sensibilità con il numero di falsi positivi per immagine. La curva cresce rapidamente nella regione a basso numero di FP/img: i primi falsi positivi ammessi permettono di recuperare molte ground truth. Successivamente la curva tende ad appiattirsi, indicando che ulteriori falsi positivi producono incrementi di sensibilità sempre più piccoli. L'asse della sensibilità è rappresentato in scala logaritmica per rendere più leggibile anche la parte iniziale della curva.

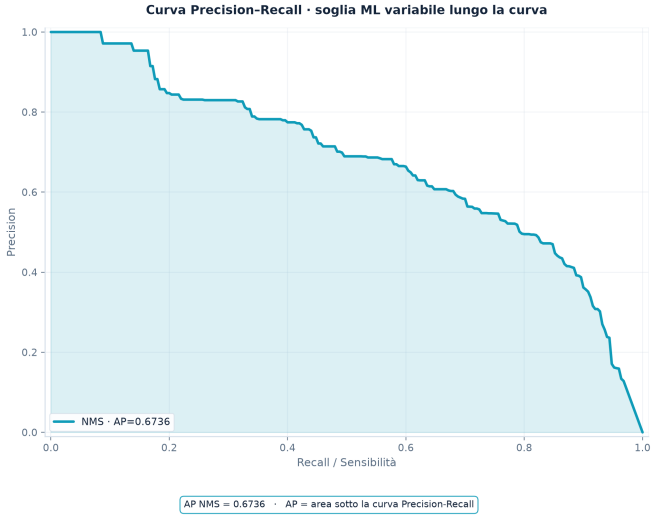


Figura 11: Curva Precision–Recall della configurazione NMS sul test set. L'Average Precision è AP = 0.6736.

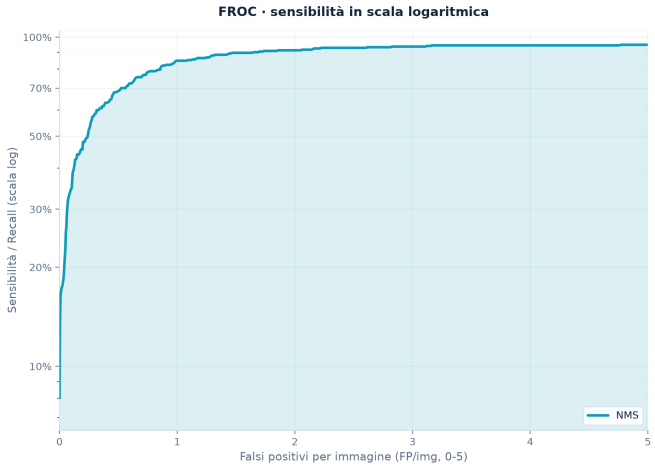


Figura 12: FROC della configurazione NMS sul test set: falsi positivi per immagine contro sensibilità, con asse della sensibilità in scala logaritmica.

8. Interfaccia grafica e revisione dei risultati

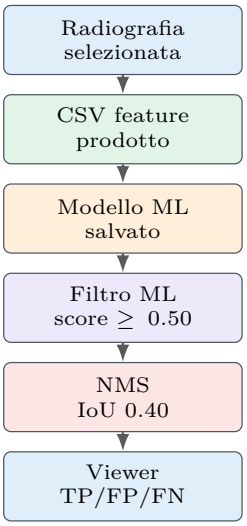


Figura 13: Flusso operativo della GUI finale: caricamento di immagine e feature, filtro ML, NMS e visualizzazione di TP, FP e FN.

La GUI rappresenta l'ultimo blocco della pipeline e supporta la revisione qualitativa dei risultati. Per l'immagine selezionata vengono caricati il CSV feature corrispondente e il modello `fracture_fp_model.pkl`. Successivamente

la GUI filtra le righe relative alla sola immagine corrente, verifica che l'immagine non appartenga al training set e calcola lo score ML delle ROI. Le ROI con score ML almeno pari a 0.50 vengono quindi sottoposte alla NMS con soglia IoU 0.40 e confrontate con le ground truth YOLO della classe 3.

8.1 Organizzazione della schermata

La schermata è organizzata come una postazione di revisione: al centro si trova il viewer radiografico, mentre i pannelli laterali riportano lo stato della pipeline, le metriche e i comandi principali. L'utente può passare tra due viste:

- **IMAGE PROCESSING**: mostra le ROI candidate lette dal CSV feature;
- **RISULTATO ML**: mostra il risultato finale dopo filtro ML e NMS.

Questa distinzione permette di confrontare direttamente le ROI candidate prodotte dall'image processing con le detection finali ottenute dopo filtro ML e NMS. La vista iniziale mostra quindi la sensibilità della fase IPA, mentre la vista finale mostra l'effetto selettivo del classificatore supervisionato e della soppressione dei duplicati.

8.2 Legenda del viewer

Tabella 8: Interpretazione dei colori e degli esiti nella GUI.

Esito	Significato
TP	Detection finale con IoU almeno 0.50 rispetto a una ground truth di frattura.
FP	Detection finale mantenuta dal sistema ma non corrispondente a una frattura annotata.
IGNORE	ROI sovrapposta a una ground truth già rilevata da un TP, con IoU $>$ 0.30; non viene conteggiata come falso positivo.
FN	Ground truth di classe 3 non coperta da alcuna detection finale valida.
GT	Annotazione reale della frattura, usata come riferimento per la revisione.

Nel viewer il colore dei box dipende dalla vista attiva. Nella vista Image Processing le ROI candidate sono mostrate come regioni proposte dal rilevatore. Nella vista Risultato ML, invece, il colore riflette la valutazione detection-level: verde per i veri positivi, arancione per i falsi positivi, rosso per le ground truth non coperte e viola per le ground truth usate come riferimento. La valutazione segue la stessa regola usata nelle curve: una detection è TP solo se raggiunge IoU ≥ 0.50 con una ground truth di classe 3; le detection finali che non soddisfano questa condizione sono FP.

8.3 Ruolo della GUI

La GUI serve soprattutto all'analisi qualitativa degli errori. Le metriche globali descrivono il comportamento medio del sistema, ma non mostrano dove e perché si verificano gli errori. Il viewer permette invece di osservare direttamente posizione, dimensione e score dei box, insieme alla loro sovrapposizione con le ground truth. Diventa così più semplice distinguere tra fratture non proposte dalla fase di image processing, ROI corrette ma scartate dal filtro ML, falsi positivi sopravvissuti alla NMS e casi in cui il box è vicino alla frattura ma non raggiunge un IoU sufficiente.

9. Conclusione

Il sistema finale riflette una scelta progettuale coerente con il problema affrontato: la fase di image processing privilegia la sensibilità e genera più candidati del necessario, mentre il filtro supervisionato e la Non-Maximum Suppression riducono la ridondanza e il numero di falsi positivi. Questo approccio risulta adeguato nel contesto delle radiografie pediatriche dell'avambraccio, dove perdere una possibile frattura è più critico che proporre una regione sospetta da sottoporre a revisione.

Il progetto realizza quindi una pipeline completa per il rilevamento automatico di fratture pediatriche. Il modulo di image processing individua le ROI candidate e salva le relative feature descrittive; il modulo Python addestra un filtro supervisionato utilizzando uno split a livello di immagine, con undersampling applicato solo al training set e selezione del modello sul validation set. La fase finale applica la NMS per mantenere le detection più affidabili e ridurre i duplicati riferiti alla stessa regione anatomica.

La valutazione finale e la GUI utilizzano una soglia ML operativa pari a 0.50, una soglia NMS pari a 0.40, selezionata sul validation set, e il criterio di correttezza IoU ≥ 0.50 per classificare una detection come vero positivo. Il confronto su validation tra le soglie NMS 0.30, 0.40 e 0.50 mostra risultati vicini, ma la soglia 0.40 ottiene il miglior F1 e mantiene un CPM elevato, rappresentando quindi un compromesso equilibrato tra soppressione dei duplicati e conservazione delle detection utili.

Le curve finali confermano un comportamento complessivamente favorevole. La curva Precision–Recall raggiunge AP $= 0.6736$, indicando che lo score ML fornisce un ordinamento utile delle detection. La FROC cresce rapidamente nella regione a basso numero di falsi positivi per immagine, mostrando che molte fratture vengono recuperate con un numero contenuto di falsi allarmi; oltre tale zona, l'aumento dei falsi positivi produce miglioramenti sempre più limitati della sensibilità.

Nonostante questi risultati, la precisione non è ancora sufficiente per rendere il sistema autonomo. La pipeline deve quindi essere interpretata come uno strumento di supporto alla revisione: evidenzia le regioni sospette, riduce la quantità di ROI da controllare e permette di analizzare in modo coerente TP, FP e FN. La decisione clinica richiede comunque l'interpretazione finale del radiologo.